



# Recomendador de Revistas Científicas mediante Ciencia de Datos

En la era actual, la explosión de publicaciones científicas presenta un desafío creciente para los investigadores. **Elegir la revista más adecuada para sus trabajos.**

Nuestro objetivo principal es diseñar un sistema que, a partir del texto de un artículo, recomiende automáticamente la revista científica más idónea.

Presentado por: Eduardo Ortega Zerpa

# Datos utilizados: La base de nuestro sistema

Para entrenar y evaluar nuestro recomendador, hemos compilado un robusto conjunto de datos compuesto por **artículos científicos publicados entre 2020 y 2024** en destacadas revistas de Elsevier.

Consideramos cuatro revistas clave, cubriendo diversas áreas:

- Applied Ergonomics
- Expert Systems with Applications
- Journal of Visual Communication and Image Representation
- Neural Networks

Cada artículo procesado incluye los siguientes campos esenciales:

- **Título**
- **Resumen**
- **Palabras clave**
- **Año**
- **DOI**
- **Revista** (la etiqueta de clase para nuestro modelo)

□ El texto de entrada utilizado por los modelos se construye concatenando el título, el resumen y las palabras clave, creando un documento unificado por artículo.

# Extracción automática y preparación de datos

## Configuración Global

Establecimiento de API key, rangos de años y revistas objetivo.

## Filtrado por DOI

Aseguramiento de que solo se procesan artículos de Elsevier.

## Enriquecimiento con OpenAlex

Adición de palabras clave y conceptos para mayor contexto semántico.

## Búsqueda en Scopus

Identificación de artículos relevantes por revista y año.

## Recuperación de ScienceDirect

Obtención de detalles completos (resumen, título, etc.).

## Normalización y Almacenamiento

Organización final de los datos en formato JSON, estructurados por revista y año.

# Metodología de Clasificación: Dos Enfoques

Implementamos dos enfoques complementarios para la clasificación de artículos, combinando la eficiencia de los modelos clásicos con la capacidad semántica del Deep Learning.

## 1. Modelo Clásico: TF-IDF + SVM

- **Representación:** TF-IDF (Term Frequency-Inverse Document Frequency), para ponderar la importancia de las palabras.
- **Clasificador:** Linear SVM (Support Vector Machine).
- **Implementación:** Desarrollado con scikit-learn.
- **Ventajas:** Eficiente computacionalmente y muy robusto para vocabulario específico.

## 2. Modelo de Deep Learning: BERT

- **Modelo:** BERT (bert-base-uncased), un modelo de Transformers pre-entrenado.
- **Entrenamiento:** Fine-tuning con la librería Transformers de Hugging Face.
- **Características:** Tokenización subword y comprensión del contexto global del texto.
- **Capacidad:** Mayor riqueza semántica y mejor manejo de la ambigüedad.

El conjunto de datos se dividió de forma estratificada: **80% para entrenamiento** y **20% para test**, asegurando una distribución equitativa de las clases.

# Resultados Principales: Comparativa y Rendimiento

La evaluación de ambos modelos reveló diferencias significativas en su capacidad para recomendar revistas científicas, destacando las fortalezas de cada enfoque.

## Modelo TF-IDF + SVM

- **Rendimiento:** Muy buen desempeño en revistas con vocabulario altamente específico, logrando un **F1-score superior a 0.9** en áreas como "Applied Ergonomics" y "Expert Systems with Applications".
- **Desafíos:** Presentó dificultades en revistas con un solapamiento temático más pronunciado, donde la distinción semántica es más complicada.



### Métricas de Evaluación

F1-score por revista



### Métricas de Evaluación

Accuracy por revista



### Métricas de Evaluación

Matriz de confusión normalizada

# Conclusiones Finales

## Sistema Automático Desarrollado

Hemos logrado construir un sistema efectivo de recomendación de revistas científicas.

## Sistemas Híbridos

La combinación de enfoques es clave para la escalabilidad.



## Eficiencia del Modelo Clásico

Rápido, eficiente y una excelente línea base para el problema.

## Superioridad de BERT

Ofrece un mejor rendimiento global y generaliza en dominios complejos.

## Desafío Persistente

El solapamiento semántico entre revistas sigue siendo una complejidad.